library(dplyr) library(magrittr)



Curso_R %>% filter(city == 'Corrientes')

BIENVENIDOS AL TALLER

LENGUAJE R DESDE CERO

COORDINADORA UNNE: MG. SONIA MARIÑO

DICTANTES

- PHD. ROXANA VILLAFAÑE
- LIC. EN SIST. PATRICIA A.LOTO

Lunes 26 de agosto de 2019.

PARTE 1

REPASO

IMPORTACIÓN DE DATOS



Breve Repaso

¿Cómo instalamos un paquete?

- install.packages ("nombre_del_paquete")
- library (nombre_del_paquete)





Importación de datos en R

#Por medio de read.csv()

#Por medio de read.table()

- Iris <- read.csv("E:/DATASETS/iris.csv")
- View(iris)

- mtcars <- read.table("E:/DATASETS/mtcars.txt")
- mtcars <-read.table("E:/DATASETS/mtcars.txt",</p>
 - header=TRUE)
- View(mtcars)



Importación de datos en R

#También podemos importar otro tipo de datos mediante el paquete readxl. Permite leer archivos

con formato (.xls and .xlsx) into R

Ejemplo:

- install.packages ("readxl")
- library (readxl)
- estadis <- read_xl ("estadistica2009.xlsx")



Hoy hablamos sobre...


PARTE 1: DATOS ORDENADOS
CON TIDYR

Funciones más importantes

PARTE 2: MANIPULACIÓN DE DATOS CON DPLYR


Funciones más importantes

Operador %>%






DATA SCIENCE WORKFLOW



PARTE 2 ORDENAR DATOS CON tidyr

TIDY DATA





- 1. Cada **variable** está en su **columna**
- 2. Cada **observación** está en una **fila**
- 3. Cada tipo de observación está en una tabla aparte

LAS BASES DE DATOS PARA NUESTRO TRABAJO



install.packages ("devtools")

 $devtools::install_github("rstudio/EDAWR")$

storms

storm	wind	pressure	date
Alberto	110	1007	2000-08-12
Alex	45	1009	1998-07-30
Allison	65	1005	1995-06-04
Ana	40	1013	1997-07-01
Arlene	50	1010	1999-06-13
Arthur	45	1010	1996-06-21

cases

Country	2011	2012	2013
FR	7000	6900	7000
DE	5800	6000	6200
US	15000	14000	13000

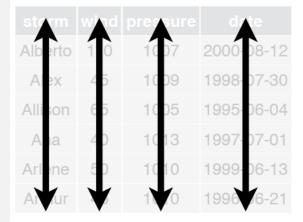
pollution

city	particle size	amount (µg/m³)
New York	large	23
New York	small	14
London	large	22
London	small	16
Beijing	large	121
Beijing	small	56


TIDY DATA



storms



cases



pollution

city	particle size	amount (µg/m³)
New York	large	≥23 ♦
New York	small	14
Lordon	large	>22
Lordon	small	16
Be ing	large	121
Beving	small	56

- Storm name
- Wind Speed (mph)
- Air Pressure
- Date

- Country
- Year
- Count

- City
- Amount of large particles
- Amount of small particles

TIDY DATA




- Instalamos el paquete tidyr install.packages ("tidyr")
- Cargamos la librería library (tidyr)
- Funciones importantes: gather() y spread()?gather?spread



NUESTRO TURNO DE ORDENAR LOS DATOS



Ordenamos teniendo en cuenta 3 variables: country, year, n.






FUNCIÓN GATHER()



Colapsar varias columnas en una sola columna

- 1. Una columna key que contiene los nombres de las columnas
- 2. Un valor que contiene los valores de las columnas.




Country	2011	2012	2013
FR	7000	6900	7000
DE	5800	6000	6200
US	15000	14000	13000



Country	Year	n	
FR	2011	7000	
DE	2011	5800	
US	2011	15000	
FR	2012	6900	
DE	2012	6000	
US	2012	14000	
FR	2013	7000	
DE	2013	6200	
US	2013	13000	





gather (cases, "year", "n", 2:4)
set de datos
columna clave

número de columnas que colapsan

valor de la columna

NUESTRO TURNO DE ORDENAR LOS DATOS



Ordenamos teniendo en cuenta 3 variables: city, large, small.

р	ollution				
city	size	amount	оïv	particle size	amo (μg/i
New York	large	23	New York	large	>23
New York	small	14	New York	small	14
London	large	22	Lordon	large	>22
London	small	16	Lordon	small	16
Beijing	large	121	Be ing	large	12
Beijing	small	56	Bering	small	56

FUNCIÓN SPREAD()



Genera varias columnas a partir de dos columnas.

- 1. Un único valor en la columna *key* se convierte en una columna única.
- 2. Cada valor *value* se convierte en una fila en una nueva columna

spread (pollution, size, amount)

set de datos

nueva columna

nueva fila



city	size	amount
New York	large	23
New York	small	14
London	large	22
London	small	16
Beijing	large	121
Beijing	small	56

spread()

gather()

city	large	small
New York	23	14
London	22	16
Beijing	121	56

spread (pollution, size, amount)

New York 3 4

Lordon 2 6

Beying 121 56

nueva fila

set de datos

nueva columna

FUNCIÓN SEPARATE()



Permite separar una columna en varias con un separador

separate(storms, date, c("year", "month", "day"), sep = "-")

storms

pressure

1007

1009

1005

1013

1010

1010

date

2000-08-12

1998-07-30

1995-06-04

1997-07-01

1999-06-13

1996-06-21

wind

110

40

storm Alberto

Alex

Allison

Ana

Arlene

Arthur


	Sī	or	m	S


storm	wind	pressure	year	month	day
Alberto	110	1007	2000	08	12
Alex	45	1009	1998	07	30
Allison	65	1005	1995	06	04
Ana	40	1013	1997	07	1
Arlene	50	1010	1999	06	13
Arthur	45	1010	1996	06	21

FUNCIÓN UNITE()



Permite unir columnas en una sola







DPLYR



- Paquete que nos ayuda a transformar datos tabulares.
- El paquete dplyr fue desarrollado por Hadley Wickham y es un versión optimizada de su paquete plyr.
- Proporciona una "gramática" (particularmente verbos) para la manipulación y operaciones con data frames.
- Instalación:

install.packages("dplyr") library(dplyr) install.packages("nycflights13") library(nycflights13) Extraer variables existentes: select()

Extraer observaciones existentes: filter()

Derivar nuevas **variables**: **mutate()**

Cambiar la unidad de análisis: summarise()

Organizar filas por variables: arrange()



Función **SELECT()**



select()

storms

storm	wind	pressure	date
Alberto	110	1007	2000-08-12
Alex	45	1009	1998-07-30
Allison	65	1005	1995-06-04
Ana	40	1013	1997-07-01
Arlene	50	1010	1999-06-13
Arthur	45	1010	1996-06-21



storm	pressure
Alberto	1007
Alex	1009
Allison	1005
Ana	1013
Arlene	1010
Arthur	1010

select(storms, storm, pressure)

Función **SELECT()**



select()

storms

storm	wind	pressure	date
Alberto	110	1007	2000-08-12
Alex	45	1009	1998-07-30
Allison	65	1005	1995-06-04
Ana	40	1013	1997-07-01
Arlene	50	1010	1999-06-13
Arthur	45	1010	1996-06-21



wind	pressure	date
110	1007	2000-08-12
45	1009	1998-07-30
65	1005	1995-06-04
40	1013	1997-07-01
50	1010	1999-06-13
45	1010	1996-06-21

select(storms, -storm)

Función **SELECT()**



select()

storms

storm	wind	pressure	date	
Alberto	110	1007	2000-08-12	
Alex	45	1009	1998-07-30	
Allison	65	1005	1995-06-04	
Ana	40	1013	1997-07-01	
Arlene	50	1010	1999-06-13	
Arthur	45	1010	1996-06-21	



wind	pressure	date
110	1007	2000-08-12
45	1009	1998-07-30
65	1005	1995-06-04
40	1013	1997-07-01
50	1010	1999-06-13
45	1010	1996-06-21

select(storms, wind:date)

Función FILTER()



filter()

storms

storm	wind	pressure	date
Alberto	110	1007	2000-08-12
Alex	45	1009	1998-07-30
Allison	65	1005	1995-06-04
Ana	40	1013	1997-07-01
Arlene	50	1010	1999-06-13
Arthur	45	1010	1996-06-21



storm	wind	pressure	date
Alberto	110	1007	2000-08-12
Allison	65	1005	1995-06-04
Arlene	50	1010	1999-06-13

filter(storms, wind >= 50)

Función **FILTER()**



filter()

storms

storm	wind	pressure	date
Alberto	110	1007	2000-08-12
Alex	45	1009	1998-07-30
Allison	65	1005	1995-06-04
Ana	40	1013	1997-07-01
Arlene	50	1010	1999-06-13
Arthur	45	1010	1996-06-21



storm	wind	pressure	date
Alberto	110	1007	2000-08-12
Allison	65	1005	1995-06-04

```
filter(storms, wind >= 50,
    storm %in% c("Alberto", "Alex", "Allison"))
```



mutate()

storm	wind	pressure	date
Alberto	110	1007	2000-08-12
Alex	45	1009	1998-07-30
Allison	65	1005	1995-06-04
Ana	40	1013	1997-07-01
Arlene	50	1010	1999-06-13
Arthur	45	1010	1996-06-21



storm	wind	pressure	date	ratio
Alberto	110	1007	2000-08-12	9.15
Alex	45	1009	1998-07-30	22.42
Allison	65	1005	1995-06-04	15.46
Ana	40	1013	1997-07-01	25.32
Arlene	50	1010	1999-06-13	20.20
Arthur	45	1010	1996-06-21	22.44

mutate(storms, ratio = pressure / wind)

Función **MUTATE()**



mutate()

storm	wind	pressure	date
Alberto	110	1007	2000-08-12
Alex	45	1009	1998-07-30
Allison	65	1005	1995-06-04
Ana	40	1013	1997-07-01
Arlene	50	1010	1999-06-13
Arthur	45	1010	1996-06-21



storm	wind	pressure	date	ratio	inverse
Alberto	110	1007	2000-08-12	9.15	0.11
Alex	45	1009	1998-07-30	22.42	0.04
Allison	65	1005	1995-06-04	15.46	0.06
Ana	40	1013	1997-07-01	25.32	0.04
Arlene	50	1010	1999-06-13	20.20	0.05
Arthur	45	1010	1996-06-21	22.44	0.04

mutate(storms, ratio = pressure / wind, inverse = ratio^-1)

Función **SUMMARISE()**



summarise()

city	particle size	amount (μg/m³)
New York	large	23
New York	small	14
London	large	22
London	small	16
Beijing	large	121
Beijing	small	56



mean	sum	n
42	252	6

pollution %>% summarise(mean = mean(amount), sum = sum(amount), n = n())

Función ARRANGE()



arrange()

storms

storm	wind	pressure	date
Alberto	110	1007	2000-08-12
Alex	45	1009	1998-07-30
Allison	65	1005	1995-06-04
Ana	40	1013	1997-07-01
Arlene	50	1010	1999-06-13
Arthur	45	1010	1996-06-21



storm	wind	pressure	date
Ana	40	1013	1997-07-01
Alex	45	1009	1998-07-30
Arthur	45	1010	1996-06-21
Arlene	50	1010	1999-06-13
Allison	65	1005	1995-06-04
Alberto	110	1007	2000-08-12

arrange(storms, wind)

Función ARRANGE()



arrange()

storms

storm	wind	pressure	date
Alberto	110	1007	2000-08-12
Alex	45	1009	1998-07-30
Allison	65	1005	1995-06-04
Ana	40	1013	1997-07-01
Arlene	50	1010	1999-06-13
Arthur	45	1010	1996-06-21



storm	wind	pressure	date
Ana	40	1013	1997-07-01
Arthur	45	1010	1996-06-21
Alex	45	1009	1998-07-30
Arlene	50	1010	1999-06-13
Allison	65	1005	1995-06-04
Alberto	110	1007	2000-08-12



arrange(storms, wind, date)



Con %>% podemos reescribir

los comandos anteriores

```
select(storms, storm, pressure)
```

storms %>% select(storm, pressure)

```
storms %>% filter(wind >= 50)
```

```
storms %>%
  filter(wind >= 50) %>%
  select(storm, pressure)
```




El operador pipe nos permite una sintaxis clara y entendible



Empieza con un verbo

Empieza con un sustantivo (dataset) y luego la operación se indica con un verbo






UseR

Bradley C. Boehmke

Data Wrangling with R








- Learning R (Github) http://bit.ly/2Aaq6d3
- R studio cheatsheets (dplyr, data.table)
- Documentación del CRAN

FUENTES DE CONSULTA

Libros







Package 'dplyr' June 29, 2018 Trile A Grammar of Data Manipulation Description: A fast, consistent tool for working with data frame like objects. Type Package DRL http://dolyr.tidaverse.drg.https://github.com/tidaverse/delyr both in memory and out of memory BugReports hexps: //gignon-com/signyerso/moly//issues Imports assertition (>= 0.2.0), bindropp (>= 0.2.0,9000), give (>= 1.11), magrins (>= 1.5), methods pkgconfig (>= 2.0.1), Rb (25 2.2.2), Repp (250.) (2.15), thoughts 0.2.0), (abble (250.) Succests bints (2=0.97), calls, convice 3.0.1), DB1(2=0.73.4). obplys (>= 1.20), daplys (>= 0.0.2), explicit (>= 2.21), house Q=0.4.1), kom Q= 1.19), Lahman (2= 3.0-1), luhrydate MASS, mgey (5 e 1 8 23), mucroherchmark (5 e 1 4 4), ayetigh OS 0.2.2); markdown OS 1.8; RMySQL OS 0.10.13). RPostgreSQL (>> 0.6.2), RSQLate (>> 2.0), teambar (>> 2.0.0 Linking To BH (>= 1.58.0.1), binductin (>= 0.2.0.9080), piogr (>= 0.1.10), Repp (>x 0.12.15) Vignette Builder knitt Encoding UTF-8 Author Hactley Wickham Laut, crel (chttps://occid.org/00001-0003-4752-117X2). LazyData yes RoxygenNote 6.0.1.9000 Romain François [ant] (chupe/loccid-org/0002-2444-42365). NeedsCompilation yes Kirill Muller Janut (chape://orcid.org/0009-0002-1416-34125). RStudio (cph. fnd)

Muchas gracias!!!

iMUCHAS GRACIAS!

¿ESTAMOS EN CONTACTO?



Email: patricialoto@hotmail.com



Twitter: https://twitter.com/patriloto